

Retinexformer Notes

Abstract

在低光图像增强中，许多深度学习算法都基于Retinex理论。然而，传统的Retinex模型未考虑到暗处隐藏的污染或由光照过程引入的污染。此外，这些方法通常需要繁琐的多阶段训练流程，并且依赖卷积神经网络（CNN），在捕捉长程依赖关系方面存在局限性。本文提出了一个简单而有原则的**单阶段Retinex框架（ORF）**。ORF首先估计光照信息来增强低光图像，然后恢复污染以生成增强后的图像。我们设计了一个**光照引导的Transformer（IGT）**，利用光照表示来指导不同光照条件区域的非局部交互建模。**通过将IGT嵌入到ORF中，我们得到了我们的算法——Retinexformer**。综合的定量和定性实验表明，Retinexformer在13个基准测试中显著超过了最先进的方法。用户研究和低光目标检测的应用也揭示了我们方法的潜在实际价值。代码可在<https://github.com/caiyuanhao1998/Retinexformer>获取。

Introduction

低光图像增强是计算机视觉中的一个重要且具有挑战性的任务。它旨在改善低光图像的可视性和对比度，并恢复暗处或光照过程引入的污染（例如噪声、伪影、色彩失真等）。这些问题不仅挑战人类的视觉感知，也挑战其他视觉任务，如夜间物体检测。

因此，已经提出了大量的算法用于低光图像增强。然而，这些现有的算法都有各自的缺点。像**直方图均衡化和伽马校正**等简单方法直接放大低可见度和对比度的图像，但它们**几乎没有考虑光照因素**，因此常常产生不必要的伪影。传统的认知方法依赖于**Retinex理论**，该理论假设**颜色图像可以分解为反射率和光照**两个组件。与简单方法不同，传统方法专注于光照估计，但由于这些方法假设图像没有噪声或色彩失真，因此常常会引入严重的噪声或局部颜色失真，这与真实的低光场景不一致。

随着深度学习的快速发展，**卷积神经网络（CNN）**已被广泛应用于低光图像增强。比如，Wei等人及后续工作将Retinex分解与深度学习相结合。然而，这些方法通常**面临繁琐的多阶段训练流程**。它们采用不同的CNN来分别分解颜色图像、去噪反射率并调整光照。需要**首先独立训练这些CNN**，然后将它们连接在一起进行端到端微调。训练过程繁琐且耗时。

此外，这些基于CNN的方法在捕捉**长程依赖性和非局部自相似性**方面也存在局限性，而这些特性对于图像恢复至关重要。近年来崛起的深度学习模型——Transformer，可能为解决这些问题提供了可能性。然而，直接将**原始视觉Transformer**应用于低光图像增强可能会遇到一个问题：**计算复杂度与输入空间的大小成二次方关系**。这种计算成本可能是难以承受的。由于这个限制，一

些混合CNN-Transformer的算法（如SNR-Net）仅在U型CNN的最低空间分辨率上使用单个全局Transformer层。因此，Transformer在低光图像增强中的潜力仍未得到充分探索。

为了应对上述问题，我们提出了一种新方法——Retinexformer，用于低光图像增强。首先，我们提出了一个简单而有原则的**单阶段Retinex框架（ORF）**。通过引入扰动项来修正反射率和光照，我们修订了原始的Retinex模型。

我们的ORF首先估计光照信息，并利用它来增强低光图像。接着，ORF通过使用一个失真恢复模块来压制噪声、伪影、曝光不足/过度以及色彩失真。与之前的Retinex深度学习框架不同，这些框架通常需要多阶段训练流程，我们的ORF采用单阶段训练方式，简化了训练过程。其次，我们设计了一个光照引导的Transformer（IGT），用于建模长程依赖性。IGT的关键组件是光照引导的多头自注意力（IG-MSA）。IG-MSA利用光照表示来指导自注意力的计算，并增强不同曝光条件区域之间的交互。最后，我们将IGT嵌入到ORF中作为失真恢复器，从而得到了我们的Retinexformer方法。

如图1所示，Retinexformer在多个数据集上显著超越了最先进的方法。特别是在SID、SDSD-室内和LOL-v2-合成数据集上，性能提高了超过6 dB。

我们的贡献可以总结如下：

- 我们提出了**第一个基于Transformer的低光图像增强算法——Retinexformer**。
- 我们提出了一个**单阶段的Retinex框架（ORF）**，其训练过程简单且能够有效建模污染。
- 我们设计了一种新的自注意力机制——**IG-MSA**，利用光照信息作为关键线索，引导长程依赖建模。
- 定量和定性实验表明，Retinexformer在13个数据集上超过了最先进的方法。用户研究和低光目标检测的结果也证明了我们方法的潜在实际价值。

Related Works

低光图像增强

- **简单方法**：简单方法，如直方图均衡化和伽马校正（Gamma Correction，GC），直接放大低曝光图像的可见度和对比度。然而，**这些方法几乎不考虑照明因素，使得增强后的图像在感知上与实际正常光照场景不一致。**
- **传统认知方法**：与简单算法不同，传统方法考虑了照明因素。它们依赖于**Retinex理论**，并将低光图像的反射分量视为增强结果的合理解。举例来说，Guo等人提出通过对初始估算的照明图施加结构先验来优化它。然而，这些方法**天真地假设低光图像没有污染**，导致在增强过程中**产生严重的噪声和颜色失真**。此外，这些方法依赖于手工设计的先验，通常需要仔细的参数调整，并且在泛化能力上表现较差。

- **深度学习方法**：随着深度学习的快速发展，**卷积神经网络（CNN）**被广泛应用于低光图像增强。例如，Wei等人及其后续工作将Retinex分解与深度学习相结合。然而，这些方法通常面临繁琐的多阶段训练流程。几种CNN被用来分别学习或调整Retinex模型的不同组件。**Wang等人提出了一种一阶段的Retinex基础CNN，名为DeepUPE，直接预测照明图。**然而，**DeepUPE并未考虑到污染因素**，导致在放大低曝光图像时产生噪声和颜色失真。此外，这些基于CNN的方法在捕捉不同区域的长程依赖关系时也表现出局限性。

视觉Transformer

近年来，Transformer及其变体已被应用于许多计算机视觉任务。例如，Xu等人提出了一种SNR感知的CNN-Transformer混合网络SNR-Net，用于低光图像增强。然而，由于**全局多头自注意力（MSA）的巨大计算开销**，SNR-Net仅在**U形CNN的最低分辨率上使用单个全局Transformer层**。Transformer在低光图像增强中的潜力尚未得到充分发挥。

Method

下图展示了我们方法的总体架构。




Figure 2. The overview of our method. (a) Retinexformer adopts the proposed ORF that consists of an illumination estimator (i) and a corruption restorer (ii) IGT. (b) The basic unit of IGT is IGAB, which is composed of two layer normalization (LN), an IG-MSA and a feed-forward network (FFN). (c) IG-MSA uses the illumination representations captured by ORF to direct the computation of self-attention.

图 2(a)：

- Retinexformer 基于单阶段 Retinex 框架（One-stage Retinex-based Framework, ORF）。

- ORF 由一个**照明估计器** (illumination estimator) (i) 和一个**失真恢复器** (corruption restorer) (ii) 组成。
- 我们设计了一个**照明引导 Transformer** (Illumination-Guided Transformer, IGT) 来充当失真恢复器的角色。

图 2(b) :

- IGT 的基本单元是**照明引导注意力块** (Illumination-Guided Attention Block, IGAB) , 它由两个层归一化 (LN) 、一个**照明引导多头自注意力** (Illumination-Guided Multi-head Self-Attention, IG-MSA) 模块和一个前馈网络 (FFN) 组成。图 2(c) 展示了 IG-MSA 的细节。

3.1 单阶段 Retinex 框架 (One-stage Retinex-based Framework, ORF)

根据 Retinex 理论 , 一个低光图像 $I \in R^{H \times W \times 3}$ 可以被分解为一个反射率图像 $R \in R^{H \times W \times 3}$ 和一个照明图 $L \in R^{H \times W}$, 其关系为 :

$$I = R \odot L \quad (1)$$

其中 $\odot$ 表示逐元素乘法。

就是Retinex理论的基本假设。

该 Retinex 模型假设 I 是无损坏 (corruption-free) 的 , 这与真实的低曝光场景不一致。

我们分析得出 , 损坏主要来源于两个因素 :

首先 , 暗场景的高 ISO 和长曝光拍摄设置不可避免地会引入噪声和伪影 ;

其次 , **亮化过程 (light-up process)** 可能会**放大噪声和伪影** , 同时还会造成**欠曝光/过曝光以及颜色失真** , 如图 2(a) 中放大的局部区域 i 和 ii 所示。

为了建模这些损坏 , 我们通过在 R 和 L 中分别引入扰动项 , 重新公式化公式 (1) :

$$I = (R + \hat{R}) \odot (L + \hat{L}) = R \odot L + R \odot \hat{L} + \hat{R} \odot (L + \hat{L}) \quad (2)$$

其中 $\hat{R} \in R^{H \times W \times 3}$ 和 $\hat{L} \in R^{H \times W}$ 表示扰动项。我们将 R 视为一个良好曝光的图像。

为了将 I 亮化 , 我们对公式 (2) 的两边逐元素相乘一个亮化映射 $\bar{L}$, 使得 $\bar{L} \odot L = 1$, 得到 :

$$I \odot \bar{L} = R + R \odot (\hat{L} \odot \bar{L}) + (\hat{R} \odot (L + \hat{L})) \odot \bar{L}, \quad (3)$$

$\bar{L} \odot L = 1$ 的意思是 , 亮化映射和原光照图的每个元素相乘乘积都是1 , 这样可以修正一些

过大/过小的光照点。

其中我们将后面两项看成损坏项。可以如此看待：

- $\hat{R} \odot (L + \hat{L})$ 表示隐藏在暗场景中的噪声和伪影，并且会被 $\bar{L}$ 放大；
- $R \odot (\hat{L} \odot \bar{L})$ 表示由亮化过程引起的欠曝光/过曝光及颜色失真。

我们将公式 (3) 简化为：

$$I_{lu} = I \odot \bar{L} = R + C, \quad (4)$$

其中 $I_{lu} \in R^{H \times W \times 3}$ 表示亮化后的图像， $C \in R^{H \times W \times 3}$ 表示总体损坏项。

随后，我们将 ORF 表述为：

$$(I_{lu}, F_{lu}) = \mathcal{E}(I, L_p), \quad I_{en} = \mathcal{R}(I_{lu}, F_{lu}), \quad (5)$$

其中 E 表示照明估计器 (Illumination Estimator)， R 表示失真恢复器 (Corruption Restorer)。 E 以 I 及其照明先验图 $L_p \in R^{H \times W}$ 作为输入，其中 $L_p = \text{mean}_c(I)$ ，表示沿通道方向计算每个像素的平均值。

补充：RGB三通道（红绿蓝）中，人眼感知颜色的敏感度排名是 $G > R > B$ 。

E 输出亮化图像 I_{lu} 和亮化特征 $F_{lu} \in R^{H \times W \times C}$ 。

然后，将 I_{lu} 和 F_{lu} 输入 R ，以恢复损坏并生成增强图像 $I_{en} \in R^{H \times W \times 3}$ 。

照明估计器 ($\mathcal{E}$) 的结构如图 2(a)(i) 所示。

$\mathcal{E}$ 首先使用一个 1×1 卷积将 I 和 L_p 的拼接结果进行融合。我们注意到，良好曝光的区域可以为欠曝光区域提供语义上下文信息。因此，采用一个**深度可分离卷积 (Depth-wise Separable Conv 5×5)** 来建模不同光照区域间的交互，以生成亮化特征 F_{lu} 。接着， E 使用一个 1×1 卷积来聚合 F_{lu} ，以生成亮化映射 $\bar{L} \in R^{H \times W \times 3}$ 。我们将 $\bar{L}$ 设为三通道 RGB 张量，而不是使用单通道映射，以提高其跨 RGB 通道建模非线性的能力，从而实现更好的颜色增强。然后，使用 $\bar{L}$ 在公式 (3) 中对 I 进行亮化。

讨论 (Discussion)

(i) 与以往的 Retinex 深度学习方法不同，我们的 ORF 估计的是 $\bar{L}$ 而非照明图 L ，因为如果 ORF 估计 L ，则亮化图像需通过逐元素除法 I/L 获得。计算机在处理极小值（甚至为 0）的张量时容易出错，除法操作可能导致数据溢出。此外，计算机随机产生的微小误差也会被该除法操作放大，从而导致估计不准确。因此，建模 $\bar{L}$ 更为稳健。

(ii) 先前的 Retinex 深度学习方法主要关注抑制反射图像上的噪声（即公式 (2) 中的 $\hat{R}$ ），但忽略了照明图估计误差（即公式 (2) 中的 $\hat{L}$ ），从而在亮化过程中容易产生欠曝光/过曝光和颜色失真。相比之下，我们的 ORF 同时考虑了这些损坏，并使用 $\mathcal{R}$ 来恢复它们。

3.2 照明引导 Transformer (Illumination-Guided Transformer)

先前的深度学习方法主要依赖于 CNN，在捕捉长距离依赖性方面存在局限性。一些 CNN-Transformer 混合方法，如 SNR-Net，由于全局多头自注意力（global MSA）的高计算复杂度，仅在 U 形 CNN 的最低分辨率上使用一个全局 Transformer 层。Transformer 在低光图像增强中的潜力尚未被充分挖掘。为弥补这一空白，我们设计了一个**照明引导 Transformer (IGT)**，用于充当公式 (5) 中的失真恢复器 R 。

网络结构 (Network Structure)

如图 2(a)(ii) 所示，IGT 采用三尺度的 U 形结构。IGT 的输入为亮化图像 I_{lu} 。在下采样分支中， I_{lu} 依次经过一个 3×3 卷积、一个 IGAB、一个步幅为 2 的 4×4 卷积（用于下采样）、两个 IGAB、再一个步幅为 2 的 4×4 卷积，以生成分层特征 $F \in R^{H^2 \times W^2 \times 2C}$ ，其中 $= 1, 2$ 。然后， F_2 经过两个 IGAB。接着，一个对称的上采样分支用于恢复特征分辨率，使用步幅为 2 的 2×2 反卷积（deconv）进行上采样。跳跃连接（skip connection）用于缓解下采样造成的信息丢失。上采样分支输出一个残差图像 $I_e \in R^{H \times W \times 3}$ 。最终，增强图像由 $I_{en} = I_{lu} + I_e$ 得到。

IG-MSA (照明引导多头自注意力)

如图 2(c) 所示，由 $\mathcal{E}$ 估计得到的亮化特征 $F_{lu} \in R^{H \times W \times C}$ 被输入到 IGT 的每个 IG-MSA 中。需要注意的是，图 2(c) 展示的是最大尺度的 IG-MSA，对于较小尺度，使用步幅为 2 的 4×4 卷积将 F_{lu} 下采样以匹配空间尺寸（图中省略此细节）。如前所述，全局 MSA 的计算成本极高，因此限制了 Transformer 在低光图像增强中的应用。为此，IG-MSA 将单通道特征图视为一个 token，并计算自注意力。

首先，输入特征 $F_n \in R^{H \times W \times C}$ 被重塑为 tokens $\in R^{HW \times C}$ 。然后，将 分为 个头：

$$= 1, 2, \dots, \quad (1)$$

其中 $\in R^{HW \times C}$, $= C$, $= 1, 2, \dots$ 。

图 2(c) 中仅展示了 $= 1$ 的情况，为简化起见省略了一些细节。

对于每个头，使用三个无偏置的全连接层将 线性映射为查询、键 和值：

$$= W, \quad = W, \quad = W, \quad (2)$$

其中 $W, W, W \in R^{\times}$ 为可学习参数，表示转置。我们注意到，同一图像的不同区域可能具有不同的光照条件。暗区通常具有更严重的损坏且更难恢复，而光照较好的区域可以提供语义上下文信息，帮助增强暗区。因此，我们利用亮化特征 F_{lu} （编码了照明信息及不同光照区域间的交互）

来引导自注意力的计算。为了与 F_{lu} 的形状对齐，我们同样将 F_{lu} 重塑为 $\in R^{HW \times C}$ ，并将其分为 g 个头：

$$F_{lu} = [F_{lu}^1, F_{lu}^2, \dots, F_{lu}^g] \quad (9)$$

其中 $F_{lu}^i \in R^{HW \times \frac{C}{g}}$, $i = 1, 2, \dots, g$ 。

则每个头的自注意力计算为：

$$enn(F_{lu}^i, F_{lu}^i) = (F_{lu}^i \odot W) \text{ma} \left(\frac{F_{lu}^i \odot W}{\sqrt{C/g}} \right) \quad (10)$$

其中 $W \in R^{\frac{C}{g}}$ 为可学习参数，用于自适应地缩放矩阵乘积。

随后，将 g 个头的结果拼接，通过一个全连接层，再加上可学习的位置编码 $\in R^{HW \times C}$ ，得到输出 $\text{tokens}_u \in R^{HW \times C}$ 。

最后，将 tokens_u 重塑为输出特征 $F_u \in R^{H \times W \times C}$ 。

复杂度分析 (Complexity Analysis)

我们分析得出，IG-MSA 的主要计算复杂度来自于公式 (9) 中的两个矩阵乘法：

$$R^{C \times HW} \times R^{HW \times \frac{C}{g}} \quad \text{和} \quad R^{HW \times \frac{C}{g}} \times R^{\frac{C}{g}}$$

因此，IG-MSA 的复杂度可以表示为：

$$(IG) = (HW) + HW \left(\frac{C}{g} \right) = 2HW_2 = 2HWC^2 \quad (1)$$

而某些先前的 CNN-Transformer 方法（如 SNR-Net）使用的全局 MSA 的复杂度为：

$$(G) = 2(HW)^2 C \quad (11)$$

比较公式 (10) 与 (11) 可以看出， $O(G\text{-MSA})$ 对输入空间尺寸 HW 呈平方关系，这种负担很大且限制了 Transformer 在低光图像增强中的应用。相比之下， $O(IG\text{-MSA})$ 对空间尺寸是线性的。这种显著较低的计算复杂度使得 IG-MSA 可以被嵌入到网络的每个基本单元 IGAB 中，从而进一步挖掘 Transformer 在低光图像增强中的潜力。